

IESP, Lego 3, 2026.I

Lista de Exercícios 1

Pedro HGF Souza, Rogério Barbosa e Carlos Antonio Costa Ribeiro

2026-04-20

Contents

1	Instruções	3
2	Pesquisa de aprovação do governo	3
2.1	Independência	3
2.2	Probabilidade condicional à escolaridade	4
2.3	Probabilidade condicional à aprovação	4
2.4	Probabilidade marginal de ser branco	4
2.5	Valor esperado e variância	4
3	Variáveis aleatórias discretas	4
3.1	Função de massa de probabilidade	5
3.2	Valor esperado e variância	5
4	Variáveis aleatórias contínuas	5
4.1	[R] Valor esperado de variável uniforme	5
4.2	[R] Probabilidade acumulada de variável uniforme	5
4.3	[R] Probabilidade acumulada de variável normal	6
4.4	[R] Probabilidade acumulada de variável logística padrão	6
4.5	[R] Função logit	6
5	Causalidade	7
5.1	Comparação entre grupos	7
5.2	Conceitos	7
6	Casos extraconjugais	7
6.1	<i>Back-doors</i>	9

6.2	[R] Implicações testáveis do DAG	9
6.3	[R] Estimando o modelo de probabilidade linear (LPM)	9
6.4	Interpretação de coeficientes do LPM	10
6.5	[R] Cálculo de valores preditos no LPM	10
6.6	[R] Estimando o modelo logit	10
6.7	Interpretação de coeficientes do modelo logit	10
6.8	[R] Cálculo de valores preditos no logit	11
7	Seleção em observáveis	11
7.1	[R] Análise descritiva	12
7.2	[R] ATT no experimento	13
7.3	[R] ATT ingênuo nos dados não experimentais	13
7.4	[R] Estimação do propensity score	13
7.5	[R] Propensity score matching com vizinho mais próximo	14
7.6	[R] Inverse probability weighting	15
7.7	[R] Regressão	15

1 Instruções

As questões abaixo revisitam o material da primeira metade do curso.

Para respondê-las, utilize os modelos em Word e R postados juntamente com este arquivo. Todas as questões exigem respostas no documento em Word, mas somente as questões indicadas explicitamente com [R] exigem respostas em código.

Os bancos de dados em csv necessários para algumas das questões aplicadas também foram postados junto com este arquivo.

O uso de ChatGPT e demais aplicativos de IA é permitido, desde que seja explicitamente admitido pelos alunos no documento em Word. Nesses casos, a correção será mais rigorosa para evitar situações de mero copia-e-cola por parte dos alunos.

Em caso de dúvidas, enunciados ambíguos ou outros problemas, por favor entrem em contato.

Boa sorte!

2 Pesquisa de aprovação do governo

Considere a tabela abaixo, que contém dados **hipotéticos** de uma pesquisa de aprovação do governo. Suponha que os resultados são populacionais, isto é, sem incerteza amostral. Observe que o total de todas as células soma 100%.

Table 1: Avaliação sobre o governo por nível de escolaridade (%)

Escolaridade	Ótimo	Regular	Péssimo	Total
Ensino Fundamental	20	10	5	35
Ensino Médio	10	15	15	40
Ensino Superior	5	5	15	25
Total	35	30	35	100

Vamos usar esse dados para recapitular conceitos importantes de probabilidades conjuntas, marginais e condicionais.

2.1 Independência

Há independência entre o nível de escolaridade dos respondentes e a avaliação do governo? Por quê?

2.2 Probabilidade condicional à escolaridade

Qual a probabilidade condicional de achar o governo ótimo para quem tem até o ensino médio, isto é, $P(\text{Avaliação} = \text{Ótimo} \mid \text{Escolaridade} \leq \text{Ensino Médio})$?

Justifique como você chegou ao resultado.

2.3 Probabilidade condicional à aprovação

Qual a probabilidade condicional de ter ensino menor ou igual a ensino médio entre quem acha o governo ótimo?

Justifique como você chegou ao resultado.

2.4 Probabilidade marginal de ser branco

Suponha que a população se divide somente entre brancos e negros. Entre as pessoas com Ensino Fundamental, 60% são brancas, percentual que cai para 55% no Ensino Médio e para 20% no Ensino Superior.

Os brancos correspondem a qual percentual da população total, isto é, qual a probabilidade marginal de ser branco?

Justifique como você chegou ao resultado.

Consulte os slides sobre a lei da probabilidade total, caso necessário.

2.5 Valor esperado e variância

Suponha que reclassificamos a tabela, gerando uma variável binária *aprova* igual a 1 para quem acha o governo ótimo ou regular e igual a 0 para quem acha péssimo.

Qual o valor esperado e a variância dessa nova variável?

Justifique como você chegou ao resultado.

3 Variáveis aleatórias discretas

Suponha que X é uma variável aleatória discreta com função de distribuição acumulada (cdf) $F(X)$ conforme a tabela abaixo.

Table 2: CDF empírica de X

X	$F(x)$
0	0.05
1	0.10
2	0.20
3	0.40
4	0.80
5	1.00

3.1 Função de massa de probabilidade

A função de massa de probabilidade (pmf) $p(X = x)$ nos diz qual a probabilidade de X ter um valor específico x . Qual a pmf para $X = 2$?

Justifique sua resposta e interprete o resultado.

3.2 Valor esperado e variância

Qual o valor esperado e a variância de X ?

Justifique sua resposta.

Consulte os slides do nivelamento, caso necessário.

4 Variáveis aleatórias contínuas

4.1 [R] Valor esperado de variável uniforme

Suponha que X é uma variável aleatória contínua com distribuição uniforme entre 4 e 10, isto é $X \sim U(4, 10)$. Qual o valor esperado dessa variável?

Justifique conceitualmente sua resposta e apresente o código em R para obtê-la.

4.2 [R] Probabilidade acumulada de variável uniforme

Considere a mesma variável da questão anterior.

Qual a probabilidade de $X \leq 6$?

Justifique conceitualmente sua resposta e apresente o código em R para obtê-la.

4.3 [R] Probabilidade acumulada de variável normal

Suponha que a temperatura diurna durante o verão siga uma distribuição normal com média de 34 graus e variância igual a 4, isto é, $X \sim N(34, 4)$.

Qual a probabilidade de a temperatura ultrapassar 38 graus?

Justifique conceitualmente sua resposta e apresente o código em R para obtê-la.

4.4 [R] Probabilidade acumulada de variável logística padrão

Suponha uma variável X com distribuição logística padrão, isto é, com $\mu = 0$ e $s = 1$.

A função de distribuição acumulada desse tipo de variável é dada por:

$$F(X) = \frac{1}{1 + e^{-x}}$$

Qual a probabilidade de $X \geq 3$?

Justifique conceitualmente sua resposta e apresente o código em R para obtê-la.

4.5 [R] Função logit

Considere uma variável aleatória com distribuição logística padrão, como na questão anterior.

Para a distribuição logística padrão, a função logit equivale à função quantílica, isto é, à inversa da CDF: enquanto a CDF toma como *input* um valor de X e gera como *output* uma probabilidade acumulada, a função logit faz o oposto, tomando como *input* uma probabilidade e gerando como *output* o valor de X correspondente.

A fórmula da função logit é:

$$\text{logit}(p) = \log\left(\frac{p}{1-p}\right)$$

Use a função logit para obter o valor correspondente ao percentil 99% de X .

Justifique conceitualmente sua resposta e apresente o código em R para obtê-la.

5 Causalidade

5.1 Comparação entre grupos

Suponha que você quer avaliar se o encarceramento afeta a expectativa de sobrevida dos indivíduos. Para isso, você coletou dados sobre julgamentos criminais de homens entre 20 e 25 anos em um ano t e dados sobre mortalidade entre t e $t + 10$. Suponha também que todos os condenados recebem penas idênticas e são imediatamente encarcerados.

Com isso, você definiu o “tratamento” $D = 1$ para os homens que foram condenados e $D = 0$ para os que foram absolvidos. O *outcome* de interesse é o percentual de homens em cada grupo que morreu entre t e $t + 10$.

Para estimar o efeito causal do encarceramento, você comparou a proporção de óbitos nos dois grupos. Ao analisar os dados, você observou que 10% dos encarcerados faleceram precocemente, contra apenas 5% dos absolvidos. A partir daí, você conclui que o efeito médio do tratamento sobre os tratados (ATT) é de 5pp, ou seja, o encarceramento aumenta a proporção de óbitos em 5 pontos percentuais.

Considerando o que discutimos em aula sobre identificação, quais as principais objeções que podem ser feitas às suas conclusões? Responda em no máximo três parágrafos, fazendo uso dos conceitos relacionados a DAGs **e/ou** resultados potenciais.

5.2 Conceitos

Explique, em suas próprias palavras, os seguintes conceitos:

1. Resultados potenciais
2. Estimandos
3. Independência ou ignorabilidade perfeita
4. Independência condicional ou ignorabilidade estrita
5. Seleção em não observáveis


Para facilitar, nas suas explicações, suponha que estamos analisando o efeito de um tratamento binário D sobre uma variável de interesse Y .

Responda em, no máximo, dois parágrafos para cada conceito.

6 Casos extraconjugais

Suponha que você quer estudar os efeitos causais de ter filhos sobre a probabilidade de envolvimento em casos extraconjugais (*affairs*) entre casais heterossexuais. Para isso, você

elaborou o DAG abaixo:



Para a análise empírica, utilize os dados do arquivo **affairs.csv**, que contém uma amostra com 601 observações de indivíduos casados e as seguintes variáveis:

- **id**: número de identificação do respondente
- **homem**: sexo do respondente (mulher = 0, homem = 1)
- **idade**: idade do respondente, em anos
- **ensino_superior**: respondente possui ensino superior? (não = 0, sim = 1)
- **religiosidade**: grau de religiosidade do respondente, medido em uma escala contínua de 1 (não religioso) até 5 (muito religioso)
- **ocupacao**: ocupação do respondente, com as categorias...
 - estudante = 1
 - trabalhador manual pouco qualificado = 2
 - trabalhador não manual de rotina = 3
 - trabalhador não manual qualificado = 4
 - gerentes e supervisores = 5
 - profissional altamente qualificado = 6
- **tempo_casamento**: tempo de casamento, em anos
- **tem_filhos**: respondente tem filhos? (não = 0, sim = 1)

- **satisfacao**: grau de satisfação com o casamento, medido em uma escala contínua de 1 (muito infeliz) até 5 (muito feliz)
- **affair**: respondente teve algum caso extraconjugal no último ano? (não = 0, sim = 1)

Ou seja, as variáveis **renda**, **U1** e **U2** são não observadas.

6.1 *Back-doors*

Supondo que o DAG está correto, quais são os controles necessários para fechar todos os *back-doors* abertos entre o tratamento (*tem_filhos*) e o resultado de interesse (*affair*)? As variáveis observadas são suficientes para isso?

Justifique sua resposta.

6.2 [R] Implicações testáveis do DAG

Uma maneira de avaliar um DAG é extraindo implicações testáveis a partir dos dados observados.

O que o DAG prevê sobre a associação marginal entre sexo e tempo_casamento?

Use a função `cor()` para calcular a correlação de Pearson entre as variáveis `homem` e `tempo_casamento` e apresente o resultado.

Em termos substantivos, o valor obtido é consistente com a predição do DAG?

Justifique.

6.3 [R] Estimando o modelo de probabilidade linear (LPM)

Estime um modelo de probabilidade linear - isto é, um modelo OLS em que a variável dependente é binária - incluindo o tratamento e somente as variáveis independentes necessárias para fechar os *back-doors*, conforme sua resposta acima.

Para isso, use a função `feols` do pacote `fixest`, com a opção `vcov = "VC1"` para obter erros-padrão corrigidos pelo estimador de White.

Não se esqueça de recodificar como factor as variáveis categóricas relevantes. Não inclua interações nem termos não-lineares.

Apresente o código para estimar o modelo e exibir os coeficientes e erros-padrão.

6.4 Interpretação de coeficientes do LPM

Suponha que sua hipótese de pesquisa é que ter filhos aumenta a probabilidade de casos extraconjugais.

Interprete o coeficiente estimado para `tem_filhos`, tanto do ponto de vista estatístico quanto à luz da sua hipótese.

6.5 [R] Cálculo de valores preditos no LPM

Qual a probabilidade predita de *affair* para homens de 50 anos, casados há exatamente um ano, sem filhos, sem ensino superior, muito religiosos, ocupados em trabalho não manual de rotina e muito satisfeitos com o casamento?

Caso alguma dessas características não esteja em seu modelo, simplesmente ignore. Use somente os coeficientes do modelo que fecha os *back-doors*.

O valor predito pode ser calculado manualmente, mas recomendamos o uso da função `predict()` no R. Basta criar um novo `data.frame` com os mesmos nomes de variáveis e os valores desejados e, em seguida, executar `predict(novo_dataframe)`.

Interprete seu resultado à luz das limitações do modelo de probabilidade linear.

6.6 [R] Estimando o modelo logit

Estime um modelo logit usando as mesmas variáveis do LPM, e apresente os coeficientes e erros-padrão.

O modelo logit pode ser estimado no R com a função `glm()` e a opção `family = binomial(link = "logit")`.

6.7 Interpretação de coeficientes do modelo logit

Suponha a mesma hipótese de pesquisa enunciada acima – ter filhos aumenta a probabilidade de casos extraconjugais.

Interprete o coeficiente estimado para `tem_filhos`, tanto do ponto de vista estatístico quanto à luz da sua hipótese.

6.8 [R] Cálculo de valores preditos no logit

Vamos repetir a predição anterior: qual a probabilidade predita de *affair* para homens de 50 anos, casados há exatamente um ano, sem filhos, sem ensino superior, muito religiosos, ocupados em trabalho não manual de rotina e muito satisfeitos com o casamento?

Caso alguma dessas características não esteja em seu modelo, simplesmente ignore. Use somente os coeficientes do modelo que fecha os *back-doors*.

O valor predito pode ser calculado manualmente, mas recomendamos o uso da função `predict()` no R. Basta criar um novo `data.frame` com os mesmos nomes de variáveis e os valores desejados e, em seguida, executar `predict(novo_dataframe)`.

No logit, o valor predito **não** é a probabilidade predita. Para converter o valor predito em probabilidade predita, é preciso aplicar a função inversa da logística. No R, isso pode ser feito com a função `plogis()`.

7 Seleção em observáveis

Em seu artigo clássico, LaLonde (1986) comparou o desempenho de métodos não experimentais com métodos experimentais. Posteriormente, Dehejia e Wahba (1999) e Imbens e Xu (2024) reanalisaram os mesmos dados.

Os dados experimentais foram obtidos do o National Supported Work Demonstration (NSW), um programa que oferecia treinamento e aconselhamento para trabalhadores vulneráveis, que posteriormente eram encaminhados para empregos. Na sua implementação, entre 1976 e 1977, o NSW contou como um experimento com alocação aleatória de indivíduos entre os grupos de tratamento e controle.

O dados não experimentais (ou observacionais) vieram do Current Population Survey, uma pesquisa domiciliar americana.

A pergunta dele era se os métodos então existentes baseados em seleção em observáveis conseguiriam chegar a resultados semelhantes à avaliação experimental.

Vamos replicar versões simplificadas dessas análises. Para isso, analisaremos empiricamente dois arquivos diferentes:

- **lalonde_experimento.csv** contém uma subamostra dos dados experimentais do NSW para 185 indivíduos do grupo de tratamento e 260 do grupo de controle
- **lalonde_cps.csv** contém os dados experimentais para os 185 do grupo de tratamento, mas o grupo de controle agora é formado por dados observacionais para todos os

homens entre 16 e 55 anos que participaram do CPS americano (n = 15992)

Os dois arquivos contêm as mesmas variáveis:

- **data_id**: fonte dos dados, com duas categorias
 - “Dehejia-Wahba Sample” = dados experimentais da subamostra analisada por Dehejia e Wahba (1999)
 - “CPS1” = dados não experimentais obtidos do Current Population Survey
- **treat**: indivíduo foi tratado? (variável binária)
- **age**: idade, em anos
- **agesq**: idade ao quadrado
- **agecube**: idade ao cubo
- **education**: anos de escolaridade
- **educationsq**: anos de escolaridade ao quadrado
- **black**: respondente é negro?
- **hispanic**: respondente é hispânico? (variável binária)
- **married**: respondente é casado? (variável binária)
- **nodegree**: respondente terminou o ensino médio? (variável binária)
- **re74**: rendimento anual em 1974
- **re74sq**: rendimento anual em 1974 ao quadrado
- **re75**: rendimento anual em 1975
- **re75sq**: rendimento anual em 1975 ao quadrado
- **re78**: rendimento anual em 1978
- **u74**: indivíduo estava desempregado em 1974? (variável binária)
- **u75**: indivíduo estava desempregado em 1975? (variável binária)
- **sample**: classificação da amostra, com três categorias
 - 1 = indivíduos tratados da amostra experimental (n = 185)
 - 2 = indivíduos não tratados da amostra experimental (n = 260)
 - 3 = indivíduos não tratados da amostra não experimental (n = 15992)

Em todas as variáveis binárias (ou *dummy*), “não” é igual a zero e “sim” é igual a 1.

Para análises mais completas, ver os arquivos de replicação de Imbens e Xu (2024), disponíveis em <https://yiqingxu.org/tutorials/lalonde/>.

7.1 [R] Análise descritiva

Produza o código em R necessário para construir tabelas descritivas comparando as médias das variáveis `age`, `education`, `black`, `married` e `re74` e `re75` para os grupos de tratamento e de controle dos dois arquivos – isto é, você vai produzir uma tabela

comparativa para os dados experimentais (**lalonge_experimento.csv**) e outra para os dados não experimentais (**lalonge_cps.csv**).

Interprete os resultados respondendo às seguintes perguntas:

- Qual dos dois grupos de controle é mais parecido com o grupo tratado?
- Por que avaliamos a comparabilidade dos grupos olhando somente características fixas ou pré-tratamento?
- Por que usar algum tipo de estratégia de *matching* nesse caso?

Compare só as estimativas de ponto, ignorando a incerteza amostral.

7.2 [R] ATT no experimento

Produza o código em R para estimar o efeito médio do tratamento sobre os tratados (ATT) usando os dados experimentais (**lalonge_experimento.csv**).

- Para isso, considere que a variável de *outcome* relevante é a remuneração recebida em 1978 (**re78**).
- Lembre-se que, como esses dados são experimentais, podemos obter o ATT a partir da simples diferença de médias entre tratados e controles.

7.3 [R] ATT ingênuo nos dados não experimentais

Produza o código em R para estimar o ATT usando os dados não experimentais (**lalonge_cps.csv**).

- Considere as mesmas definições acima
- Estime o “ATT ingênuo” por simples diferença de médias entre grupos.

Compare os resultados com os obtidos no item anterior.

- O que estimativa ingênua diz sobre os efeitos do programa?
- À luz dos itens anteriores, por que essa estimativa é claramente viesada?

7.4 [R] Estimação do propensity score

Produza o código em R para estimar o *propensity score* para os dados não experimentais (**lalonge_cps.csv**), crie uma coluna com as probabilidades preditas de tratamento, e, por fim, produza uma tabela com os valores médios do *propensity score* para tratados e controles, interpretando os resultados.

- Para criar o *propensity score*, estime um modelo logit usando `treat` como variável independente e `age`, `agesq`, `agecube`, `education`, `educationsq`, `black`, `hispanic`, `married`, `re74`, `re74sq`, `re75`, `re75sq`, `u74` e `u75` como variáveis independentes. Não se esqueça de salvar o resultado em algum objeto (por ex., `modelo_logit`).
- Os valores preditos ficam salvos dentro do objeto gerado pelo GLM em um vetor chamado `fitted`. Para acrescentá-los ao data frame original, basta executar, por exemplo, `cps %>% mutate(ps = modelo_logit$fitted)`
- Seu código deve reportar o *propensity score* médio para tratados e controles.

7.5 [R] Propensity score matching com vizinho mais próximo

O método mais tradicional de *matching* é usando o *propensity score* para parear cada observação com o vizinho mais próximo. Para fins didáticos, vamos aplicar a versão mais simples possível desse método, usando o *propensity score* estimado acima.

Faça o download do pacote `MatchIt` e carregue esse pacote na memória. Em seguida, execute os comandos abaixo.

- No código, `cps` é o nome do data frame que contém os dados de `lalonge_cps.csv`.

Com base nos resultados obtidos, responda:

- O pareamento melhorou ou piorou o equilíbrio das covariadas? Dê exemplos.
- Qual o *propensity score* médio de tratados e dos controles pareados? Houve melhora em relação à comparação do item anterior?
- Qual a estimativa de ponto para o ATT? Considerando que o ATT experimental é o correto, a estimativa com *propensity score matching* aumentou ou diminuiu o viés em relação ao ATT “ingênuo” visto acima?

```
# carrega o pacote
library(MatchIt)
# Propensity score matching com o matchit
M <-
  matchit(formula = treat ~ age + agesq + agecube + education + educationsq +
           black + hispanic + married + re74 + re74sq + re75 + re75sq +
           u74 + u75,          # formula que usamos para o logit
           data = cps,         # data frame com os dados
           distance = cps$ps,  # propensity scores estimados
           estimand = 'ATT',   # estimando vai ser o ATT
           method = 'nearest', # pareamento por proximidade
```

```

ratio = 1,          # com apenas 1 vizinho
discard = 'treated', # restricao de suporte comum
replace = FALSE)    # sem reposicao
# Equilibrio das covariadas antes e depois do pareamento
summary(M)
# data frame so com casos pareados
M_df <- match_data(M)
# Calculo do ATT para re78
lm(re78 ~ treat, data = M_df)

```

7.6 [R] Inverse probability weighting

Vamos agora implementar uma versão bem simplificada do estimador por IPW. Como vimos em aula, no IPW nós não fazemos pareamento direto, mas sim usamos os *propensity scores* como pesos.

Nesse modelo simplificado, a estimação é fácil. Produza o código de R que faça as seguintes etapas:

- Cria uma variável `ipw` que toma valor 1 para tratados e $ps / (1 - ps)$ para controles (ver slide 24 da aula 5)
- Para estimar o ATT basta calcular a diferença de médias, ponderando pela variável `ipw`, ou, alternativamente, usar o comando `lm()` para estimar uma regressão OLS de `re78` (nosso *outcome*) sobre a variável binária de tratamento, acrescentando a opção `weights = ipw`.

Qual o ATT que você obteve? Compare o resultados com as estimativas anteriores.

7.7 [R] Regressão

Produza o código em R que estime duas regressões de `re78` sobre `treat` e as demais variáveis incluídas na estimação do logit acima. A primeira regressão deve ser executada sem pesos (OLS), mas a segunda deve incluir o argumento `weights = ipw` (WLS).

Quais os coeficientes encontrados em cada modelo? Qual dos dois está mais próximo do ATT experimental? Como você explica isso?

- Consulte o material da aula 6 em caso de dúvida.